

Anonimização do Adult Dataset com Análise de Risco e Utilidade

Segurança e privacidade 25/26

Victor de Vargas Lopes – 202400863

Ezequiel Tchimbaya Cachapeu Paulo - (202400891)

Pedro da Graça - (202406955)

1. Preparação dos dados e classificação dos atributos

O objetivo deste trabalho foi anonimizar o Adult Dataset no ARX, avaliando simultaneamente o risco de reidentificação e a utilidade dos dados após a aplicação de modelos de privacidade. Antes da importação no ARX, os atributos **fnlwgt** e **education-num** foram removidos no Excel. O atributo **fnlwgt** representa um peso estatístico da amostra e não é uma característica analítica direta do indivíduo; **education-num** foi retirado por ser redundante com **education**.

Não foram identificados atributos diretamente identificadores. O atributo **income** foi classificado como sensível, pois representa uma informação económica privada. Os restantes atributos foram tratados como quasi-identifiers, porque a sua combinação pode permitir a reidentificação de indivíduos.

Tipo	Atributos
Identificadores diretos	Nenhum
Quasi-identifiers	age, workclass, education, marital-status, occupation, relationship, race, sex, capital-gain, capital-loss, hours-per-week, native-country
Sensitive attribute	income
Removidos antes do ARX	fnlwgt, education-num

Tabela 1 - Classificação dos atributos utilizada no ARX.

2. Coding models e hierarquias de generalização

Foram utilizadas hierarquias para transformar valores específicos em categorias mais gerais. A generalização reduz a capacidade de distinguir indivíduos, enquanto a supressão é usada pelo ARX quando a generalização não é suficiente para satisfazer os modelos de privacidade.

Atributo	Exemplo de generalização
age	idade exata -> intervalo -> *
education	nível específico -> grupo educacional -> *
marital-status / relationship	categoria específica -> categoria agregada -> *
capital-gain, capital-loss, hours-per-week	valor numérico -> intervalo -> *
native-country	país -> região/continente -> *

Tabela 2 - Exemplos de coding models/hierarquias aplicadas.

3. Risco de reidentificação no dataset original

Antes da anonimização, o dataset apresentou risco muito elevado. No modelo de atacante prosecutor, o risco médio era de 87,50346%, o maior risco era 100% e 80,54114% dos registos estavam afetados pelo maior risco. Estes valores indicam que a combinação dos quasi-identifiers gerava muitos grupos pequenos ou únicos, tornando o dataset inadequado para publicação sem proteção.

Cenário	Risco médio (%)	Maior risco (%)	Reg. maior risco (%)	Registos em risco (%)	Sample uniques (%)
Original	87,50346	100	80,54114	95,5032	80,54114

Tabela 3 - Principais métricas de risco do dataset original.

A distribuição de riscos observada no ARX reforçou este resultado: a maior parte dos registos encontrava-se em faixas altas de risco, especialmente acima do limiar de 50%.

4. Iteração preliminar e decisão de ajuste

Foi executada uma primeira transformação com $k=2$ e $l=2$, sem restringir maximum levels. O resultado reduziu bastante o risco, mas **comprometeu a utilidade**: vários atributos passaram a aparecer totalmente generalizados ou suprimidos, como age, education, occupation, capital-gain e hours-per-week. Por isso, **esta iteração foi tratada como teste preliminar**, não como modelo escolhido.

Modelo	Configuração	Risco médio (%)	Maior risco (%)	Discernibility (%)	N-U entropy (%)	Decisão
0	$k=2$, $l=2$, s/ maximum levels	0,06142	5	76,04001	10,7176	rejeitado por baixa utilidade

Tabela 4 - Resultado da iteração preliminar.

A partir desta observação, no Modelo 1 foram definidos **maximum levels** para age, education, marital-status e relationship, para evitar que atributos relevantes fossem transformados totalmente em “*”.

5. Modelo 1 - k-anonymity + distinct l-diversity

O primeiro modelo combina k-anonymity com distinct l-diversity, usando income como atributo sensível. Como income possui duas classes principais, foi usado $l=2$, outros valores não seriam passíveis de avaliação com apenas duas classes. Foram testados $k=2$, $k=5$ e $k=10$, todos com limite de supressão de 5%.

Modelo	k	l	Sup.	Risco médio (%)	Maior risco (%)	Reg. maior risco (%)	Discernibility (%)	N-U entropy (%)
1A	2	2	5%	0,56644	50	0,07724	90,89045	25,83124
1B	5	2	5%	0,46483	20	0,1452	90,60792	25,6932
1C	10	2	5%	0,35234	10	0,1293	90,46936	25,47472

Tabela 5 - Resultados do Modelo 1 com variação de k.




Figura 1 - Efeito do aumento de k no risco médio e na utilidade.

Entre os modelos 1, o **Modelo 1B foi considerado o mais adequado**. O Modelo 1C apresenta o menor risco médio e o menor maior risco, mas a diferença prática face ao Modelo 1B é pequena quando comparada com a diminuição da discernibility com $k=10$. O Modelo 1B, com $k=5$, já reduz o risco médio para 0,46483%, limita o maior risco a 20% e mantém uma discernibility de 90,60792%, apresentando o melhor compromisso entre privacidade e utilidade dentro deste grupo.

Assim, o **Modelo 1B** foi selecionado como a configuração representativa do modelo k-anonymity + l-diversity para a comparação final.

6. Modelo 2 - k-anonymity + t-closeness

O segundo modelo combina k-anonymity com t-closeness para proteger income contra ataques de inferência. Nos testes com t-closeness, os maximum levels foram retirados, pois a configuração com esses limites não produziu resultados válidos. Foram avaliados $t=0,3$, $t=0,5$ e $t=0,8$, mantendo $k=2$ e supressão de 5%.

Modelo	k	t	Sup.	Risco médio (%)	Maior risco (%)	Reg. maior risco (%)	Discernibility (%)	N-U entropy (%)
2A	2	0,3	5%	0,87	20	0,54736	85,4082	25,93806
2B	2	0,5	5%	1,18223	20	0,64427	92,42191	30,69258
2C	2	0,8	5%	1,2602	20	0,7585	90,87559	29,86414

Tabela 6 - Resultados do Modelo 2 com variação de t.




Figura 2 - Efeito da variação de t no risco médio e na N-U entropy.

O valor $t=0,3$ apresentou o menor risco médio entre os testes de t-closeness, mas também reduziu bastante a utilidade, com discernibility de 85,40820%. O valor $t=0,8$ preservou uma utilidade razoável, mas apresentou o maior risco médio e maior percentagem de registos com maior risco. **O Modelo 2B, com $t=0,5$, apresentou o melhor equilíbrio:** risco médio de 1,18223%, maior risco de 20%, discernibility de 92,42191% e N-U entropy de 30,69258%.

Dessa forma, o **Modelo 2B** foi escolhido como a configuração representativa do modelo k-anonymity + t-closeness.

7. Comparação final dos modelos

A comparação final considera o dataset original, a iteração preliminar rejeitada e os melhores representantes dos dois modelos analisados: Modelo 1B e Modelo 2A. A escolha foi feita considerando simultaneamente risco de reidentificação, maior risco observado e métricas de utilidade.

Cenário	Configuração	Risco médio (%)	Maior risco (%)	Discernibility (%)	N-U entropy (%)	Decisão
Original	sem anonimização	87,50346	100	-	-	não publicável
Modelo 0	k=2, l=2, s/ maximum levels	0,06142	5	76,04001	10,7176	rejeitado
Modelo 1B	k=5, l=2, sup. 5%	0,46483	20	90,60792	25,6932	melhor equilíbrio geral
Modelo 2A	k=2, t=0,5, sup. 5%	1,18223	20	92,42191	30,69258	melhor t-closeness

Tabela 7 - Comparação final entre os cenários analisados.

8. Conclusão

Os resultados mostram que o dataset original apresentava risco de reidentificação **muito elevado**, tornando necessária a aplicação de modelos de anonimização. A iteração preliminar reduziu o risco, mas sacrificou demasiada utilidade, o que justificou a definição de limites máximos de generalização em atributos relevantes no Modelo 1.

O melhor compromisso geral foi obtido com o Modelo 1B, configurado com **k=5, l=2 e limite de supressão de 5%**. Esta configuração reduz drasticamente o risco médio, protege o atributo sensível income por l-diversity e preserva uma utilidade elevada. Embora o Modelo 1C tenha risco ligeiramente menor, o k=5 foi considerado mais adequado por atingir um nível de proteção suficiente com menor restrição do que k=10, seguindo a lógica de equilíbrio entre privacidade e utilidade.

O Modelo 2A também apresentou bons resultados, sobretudo nas métricas de utilidade, mas manteve risco médio superior ao Modelo 1B. Assim, para este dataset, **o Modelo 1B foi escolhido como resultado final mais equilibrado**.

***Uso de IA:** foi utilizado apoio de IA para estruturar o relatório a partir dos resultados obtidos no ARX. Os valores numéricos, classificações e prints foram produzidos e verificados manualmente pelo grupo.