

Anonimização do Adult Dataset com Análise de Risco e Utilidade

Segurança e Privacidade

1. Introdução e preparação dos dados

O objetivo deste trabalho foi anonimizar o Adult Dataset utilizando a ferramenta ARX, avaliando o risco de reidentificação e a utilidade dos dados após a aplicação de modelos de privacidade. Antes da importação no ARX, os atributos fnlwgt e education-num foram removidos no Excel: fnlwgt corresponde a um peso estatístico da amostra e não representa uma característica útil para a análise pretendida; education-num foi retirado por ser redundante com o atributo education.

Depois desta preparação, não foram identificados atributos diretamente identificadores, como nome, e-mail ou número fiscal. O atributo income foi classificado como sensível, pois representa informação económica privada. Os restantes atributos foram classificados como quasi-identifiers, uma vez que, quando combinados, podem permitir a reidentificação de indivíduos.

Classificação	Atributos
Identificadores diretos	Nenhum
Quasi-identifiers	age, workclass, education, marital-status, occupation, relationship, race, sex, capital-gain, capital-loss, hours-per-week, native-country
Sensitive attribute	income
Removidos antes do ARX	fnlwgt, education-num

Tabela 1 - Classificação dos atributos utilizada no ARX.

2. Coding models e risco inicial

Foram utilizadas hierarquias de generalização para os quasi-identifiers. A generalização transforma valores específicos em categorias mais amplas, como idade exata em intervalos, nível de educação em grupos educacionais, país em regiões e valores numéricos em intervalos. Quando a generalização não era suficiente para satisfazer os modelos de privacidade, o ARX também pôde recorrer à supressão.

Atributo	Exemplo de generalização
age	valor exato -> intervalo -> *
education	nível específico -> grupo educacional -> *
marital-status / relationship	categoria específica -> categoria agregada -> *
capital-gain, capital-loss, hours-per-week	valor numérico -> intervalo -> *
native-country	país -> região/continente -> *

Tabela 2 - Exemplos dos coding models/hierarquias aplicadas.

A análise inicial do dataset original mostrou risco muito elevado. No modelo de atacante prosecutor, o risco médio era de 87,50346%, o maior risco era 100% e 80,54114% dos registos estavam afetados pelo maior risco. A percentagem de registos em risco também era muito alta, com 95,5032%. Estes valores confirmam a necessidade de anonimização antes da publicação ou partilha dos dados.

Cenário	Risco médio (%)	Maior risco (%)	Registos com maior risco (%)	Registos em risco (%)
Original	87,50346	100	80,54114	95,5032

Tabela 3 - Risco de reidentificação do dataset original.

3. Iteração preliminar

Foi executada uma primeira transformação com k=2 e l=2, sem restringir os níveis máximos de generalização dos atributos. O resultado reduziu fortemente o risco médio para 0,06142% e o maior risco para 5%, mas a utilidade ficou demasiado comprometida: vários quasi-identifiers chegaram a 100% de missing/generalização, como age, workclass, education, occupation, relationship, capital-gain, capital-loss, hours-per-week e native-country. Por isso, este resultado foi considerado demasiado agressivo e não foi adotado como modelo final.

A partir desta iteração, foram definidos maximum levels para age, education, marital-status e relationship, de forma a evitar que atributos relevantes fossem totalmente transformados em “*” no Modelo 1.

4. Modelo 1 - k-anonymity + distinct l-diversity

O primeiro modelo final combina k-anonymity com distinct l-diversity, usando income como atributo sensível. Como income possui essencialmente duas classes, foi usado l=2. Foram testados k=2, k=5 e k=10, todos com limite de supressão de 5%.

Modelo	k	l	Supressão	Risco médio (%)	Maior risco (%)	Reg. maior risco (%)	Discernibility (%)	N-U entropy (%)
1A	2	2	5%	0,56644	50	0,07724	90,89045	25,83124
1B	5	2	5%	0,46483	20	0,1452	90,60792	25,69320
1C	10	2	5%	0,35234	10	0,1293	90,46936	25,47472

Tabela 4 - Resultados do Modelo 1 com variação do parâmetro k.




Figura 1 - Efeito do aumento de k no risco médio e na utilidade do Modelo 1.

Os resultados mostram que o aumento de k reduziu progressivamente o risco médio e o maior risco observado. A passagem de k=2 para k=10 reduziu o maior risco de 50% para 10%, mantendo a discernibilidade praticamente estável, de 90,89045% para 90,46936%. Assim, o Modelo 1C foi considerado o melhor resultado deste grupo, pois apresentou a maior proteção com perda de utilidade reduzida.

5. Modelo 2 - k-anonymity + t-closeness

O segundo modelo combina k-anonymity com t-closeness para proteger income contra inferência. Ao contrário do Modelo 1, os maximum levels foram retirados, pois a configuração com limites máximos não gerava resultados satisfatórios com t-closeness. Foram testados t=0,3, t=0,5 e t=0,8, mantendo k=2 e supressão de 5%.

Modelo	k	t	Supressão	Risco médio (%)	Maior risco (%)	Reg. maior risco (%)	Discernibility (%)	N-U entropy (%)
2B	2	0,3	5%	0,87000	20	0,54736	85,40820	25,93806
2A	2	0,5	5%	1,18223	20	0,64427	92,42191	30,69258
2C	2	0,8	5%	1,26020	20	0,75850	90,87559	29,86414

Tabela 5 - Resultados do Modelo 2 com variação do parâmetro t.




Figura 2 - Efeito da variação de t no risco médio e na entropia não uniforme do Modelo 2.

No Modelo 2, t=0,3 apresentou menor risco médio, mas também menor discernibility, indicando maior perda de utilidade. O valor t=0,8 preservou utilidade razoável, mas aumentou o risco médio e os registos com maior risco. O melhor equilíbrio foi observado em t=0,5, pois manteve a maior discernibility (92,42191%) e a maior N-U entropy (30,69258%) entre as três configurações, com risco médio ainda muito inferior ao dataset original.

6. Comparação final e conclusão

Cenário	Configuração	Risco médio (%)	Maior risco (%)	Discernibility (%)	N-U entropy (%)	Decisão
Original	sem anonimização	87,50346	100	-	-	não publicável
Modelo 0	k=2, l=2, sem maximum levels	0,06142	5	76,04001	10,71760	rejeitado por baixa utilidade
Modelo 1C	k=10, l=2, sup. 5%	0,35234	10	90,46936	25,47472	melhor privacidade com boa utilidade
Modelo 2A	k=2, t=0,5, sup. 5%	1,18223	20	92,42191	30,69258	melhor t-closeness

Tabela 6 - Comparação entre o dataset original, a iteração preliminar e os melhores resultados de cada modelo.




Figura 3 - Redução do risco médio nos modelos selecionados.

Comparando os resultados, ambos os modelos finais reduziram drasticamente o risco face ao dataset original. O Modelo 1C foi o mais forte em privacidade, com risco médio de apenas 0,35234% e maior risco de 10%, mantendo discernibility acima de 90%. O Modelo 2A preservou melhor algumas métricas de utilidade, especialmente discernibility e N-U entropy, mas manteve risco médio e maior risco superiores aos do Modelo 1C.

Conclui-se que, para este dataset e para os objetivos do trabalho, o melhor compromisso geral foi o Modelo 1C, com $k=10$, $l=2$ e supressão de 5%. Esta configuração protege o atributo sensível income através de I-diversity, reduz substancialmente o risco de reidentificação e evita a perda extrema de utilidade observada na iteração preliminar sem maximum levels. O Modelo 2A continua relevante como alternativa quando o objetivo principal é controlar a proximidade da distribuição do atributo sensível, mas, neste caso, apresentou menor ganho de privacidade.

Uso de IA: foi utilizado apoio de IA para estruturar e redigir o relatório a partir dos resultados obtidos no ARX. Os valores numéricos, classificações e prints foram produzidos e verificados manualmente pelo grupo.